Flujo de trabajo con agentes especializados: validación cruzada frente a partición única en German Credit

German Credit 6.1

Atlantis University

MAI 540: Machine Learning

Kevin A. García Gallardo

13 de octubre de 2026

Flujo de trabajo con agentes especializados: validación cruzada frente a partición única en German Credit

Se evaluó un modelo de aprobación de crédito con el conjunto German Credit (1,000 solicitudes, 20 variables, 30 % de créditos malos; Hofmann, 1994) repartiendo el trabajo entre tres roles ejecutados como subagentes independientes: analista de datos, ingeniero de modelos y auditor. Cada rol tiene un archivo de definición con su responsabilidad, lo que puede y no puede tocar y su entregable (*.claude/agents/*). El analista entregó el resumen de datos (sin faltantes ni duplicados; la línea base «siempre bueno» acierta .700), el ingeniero las métricas y el auditor las recalculó con código propio (55 de 55 verificaciones correctas, sin fuga de información).

Método

Se compararon un árbol de decisión y un Random Forest de scikit-learn 1.9.0 (Pedregosa et al., 2011), con hiperparámetros por defecto y *random_state* = 42. Ambos van dentro de un *Pipeline* cuyo primer paso codifica las 13 variables categóricas con *OrdinalEncoder* (categorías no vistas = −1) y deja pasar las 7 numéricas; así la codificación se ajusta solo con el entrenamiento de cada pliegue. La validación cruzada fue estratificada de 5 particiones, con mezcla y semilla 42 (Kohavi, 1995). Se reportan la media y la desviación estándar muestral de la exactitud por pliegue y la proporción de créditos malos detectados (*recall* de la clase «mala»). Para la partición única se repitió *train_test_split* 75/25 estratificado con las semillas 0 a 29 (30 repeticiones, más que las 10 exigidas).

Resultados de la validación cruzada

El árbol alcanzó una exactitud media de .698 y no supera la línea base de .700 (−0.2 pp). El Random Forest llegó a .759 (+5.9 pp) con la menor variabilidad entre pliegues. Sin embargo, el modelo más exacto detecta menos créditos malos: 37.7 % frente a 53.0 % del árbol (Tabla 1), es decir, deja pasar más de seis de cada diez créditos malos.

Tabla 1

Validación cruzada estratificada de 5 pliegues

Modelo	Exactitud M (DE)	Malos detectados M (DE)	Exactitud − base (pp)
Árbol de decisión	.698 (.019)	.530 (.046)	−0.2
Random Forest	.759 (.007)	.377 (.019)	+5.9

Nota. M = media; DE = desviación estándar muestral entre los 5 pliegues; pp = puntos porcentuales. Línea base «siempre bueno» = .700. «Malos detectados» es la proporción de créditos malos clasificados como malos.

Comparación con la partición única

Con una partición 75/25 la exactitud del árbol varió entre .608 y .720 y la del Random Forest entre .712 y .804 según la semilla (Tabla 2); con solo las semillas 0 a 9 los rangos son .608–.720 y .712–.796. El promedio de las 30 particiones difiere de la media de la validación cruzada en −1.72 pp (árbol) y −0.74 pp (Random Forest), pero una partición individual se aleja entre −9.00 y +2.20 pp (árbol) y entre −4.70 y +4.50 pp (Random Forest). La dispersión entre particiones (DE = .023 y .024) es del orden del error estándar binomial de una exactitud cercana a .75 con 250 casos de prueba (≈ .027). El recall de los malos oscila entre .347 y .653 (árbol) y entre .280 y .507 (Random Forest): una sola partición habría podido sugerir cualquier conclusión sobre qué modelo detecta más malos. La referencia es una única validación cruzada (semilla 42), por lo que la diferencia es una estimación, no un valor exacto.

Tabla 2

Partición única 75/25 con 30 semillas (0 a 29) frente a la media de la validación cruzada

Modelo	Métrica	Mín.	Máx.	M (DE)	M − M CV (pp)	Rango − M CV (pp)
Árbol de decisión	Exactitud	.608	.720	.681 (.023)	−1.72	[−9.00; +2.20]
Árbol de decisión	Malos detectados	.347	.653	.484 (.071)	−4.56	[−18.33; +12.33]
Random Forest	Exactitud	.712	.804	.752 (.024)	−0.74	[−4.70; +4.50]
Random Forest	Malos detectados	.280	.507	.377 (.064)	+0.02	[−9.67; +13.00]

Nota. M CV = media de la validación cruzada (Tabla 1). La última columna es [mínimo − M CV; máximo − M CV] en puntos porcentuales.

Evaluación crítica de la distribución

Repartir el trabajo aportó verificación independiente, no mejores cifras: ningún rol cambió un resultado. El auditor recalculó todo con código propio y sus comprobaciones coincidieron exactamente,

incluida una prueba de comportamiento del Pipeline: una categoría ausente del entrenamiento (*retraining*, 9 filas) se codificó como −1 en la validación, lo que muestra que el codificador se ajusta solo con los datos de entrenamiento. Esa evidencia es más sólida que leer el código. **Ejemplo 1 (hallazgo de un rol).** El auditor no halló ningún error de cálculo; lo que detectó fueron riesgos de interpretación: presentar la media de 30 particiones (−1.72 pp) como «la» diferencia ocultaría el −9.00 pp del árbol, y las recomendaciones del analista (escalar, aplicar logaritmos, añadir F1 y AUC) excedían lo pedido, algo que yo ya había descartado al leer el traspaso. **Ejemplo 2 (costo).** Los tres subagentes consumieron unos 318 mil tokens (90,448; 96,147 y 131,487) y cerca de 7 minutos, para algo que el script *reproducir.py* regenera en unos 50 segundos en este equipo. Además, el auditor no pudo escribir su reporte por una restricción de la herramienta y tuve que transcribirlo, lo que debilita la separación de funciones que justificaba el esquema. **Conclusión.** No medí la alternativa de una sola conversación, de modo que esto es una inferencia. Lo repetiría solo para tareas donde importe la verificación independiente (auditar fuga de información, reproducibilidad de cifras, decisiones de riesgo como el crédito), con el auditor como único rol realmente separado. No lo repetiría para una tubería pequeña y determinista como esta, donde separar analista e ingeniero costó más de lo que aportó.

Referencias

Hofmann, H. (1994). *Statlog (German Credit Data)* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5NC77

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. *Proceedings of the 14th International Joint Conference on Artificial Intelligence*, 2, 1137–1143.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825–2830.