Aplicación híbrida con verificación: una red neuronal, un texto generado y dos reglas que cierran un hueco

Jaime Lopez
Atlantis University · MAI 540: Machine Learning · Profesor: Kevin A. García Gallardo
Tarea 7.2 · 19 de octubre de 2026

La aplicación de la Clase 7 combina un Random Forest que estima la probabilidad de que un crédito sea malo, un modelo de lenguaje pequeño (Qwen2.5-0.5B-Instruct; Qwen Team, 2024) que redacta la explicación y un verificador que decide si el texto se muestra. Sobre las 200 solicitudes de prueba de German Credit (Hofmann, 1994; partición 80/20 estratificada, semilla 42) se comparó el predictor con una red neuronal, se buscó un fallo que el verificador de clase no atrapa, se cerró con dos reglas y se midió el efecto.

Red neuronal y Random Forest

La red de `crear_red` tiene 61 entradas (las categorías convertidas en columnas 0/1 más las variables numéricas estandarizadas), dos capas ocultas de 16 y 8 neuronas con ReLU y una salida: 1,137 pesos y sesgos aprendidos. Sobre las 200 solicitudes que no vio acertó .735; el Random Forest, .770 (Tabla 1). Con 200 casos el error típico de una exactitud ronda tres puntos, así que la diferencia de siete solicitudes no es concluyente, aunque la validación cruzada apunta igual (.717 frente a .755). Ambos quedan cerca de .700, la exactitud de responder siempre «bueno», y ambos memorizan el entrenamiento (1.00). La red aprende pesos continuos que combinan todas las variables en una sola superficie suave; por eso detecta más créditos malos (.533) pero es sensible a la escala y al sobreajuste con solo 800 filas. El bosque promedia 200 árboles de reglas del tipo «si la cuenta es negativa y el plazo es largo…» (Breiman, 2001), admite categorías y números sin ajustes finos y es más estable (±.010 frente a ±.024). Elegiría el Random Forest como predictor de esta aplicación; si aprobar un crédito malo costara mucho más que rechazar uno bueno, ajustaría su umbral antes de pasarme a la red, que detecta .533 de los malos contra .383.

Tabla 1

Red neuronal y Random Forest sobre las mismas 200 solicitudes de prueba

Modelo	Estructura	Exactitud entren.	Exactitud prueba	Malos detectados	Exactitud val. cruzada
Red neuronal (MLP)	61-16-8-1; 1,137 pesos	1.000	.735	.533	.717 (±.024)
Random Forest	200 árboles; 66,656 nodos	1.000	.770	.383	.755 (±.010)
Siempre «bueno»	—	—	.700	.000	—

Nota. «Malos detectados» es la proporción de los 60 créditos malos de la prueba que el modelo señaló. Validación cruzada de 5 pliegues sobre los 1,000 casos (media y desviación estándar). Salida de comparar_modelos.py.

Ejecución sobre 200 solicitudes y rechazos del verificador de clase

`main.py` recorre ahora N solicitudes (se ejecutó con 20 y con 200). El verificador de clase rechazó 9 de las primeras 20 explicaciones y 64 de las 200 (32 %). Los motivos fueron 37 llamadas «alto» con probabilidad menor de 30 % (o «bajo» con más de 60 %), 29 números que no vienen de los datos ni del modelo y 1 afirmación absoluta; un texto puede tener varios motivos. La Tabla 2 muestra dos casos reales: la solicitud 1 llama «alto» a un 26 %, y la 18 afirma «más de 60 años» sobre una persona de 57.

Un fallo que la verificación no atrapa

La solicitud 8 (43 %) pasó la verificación aunque su texto dice que la cuenta corriente está «sin saldo negativo» y el dato es «saldo negativo». El verificador no lo ve porque solo mira números (43 %,

23 años y 6 meses son correctos) y el tono en las franjas extremas, y 43 % queda en medio. No es un caso aislado: el mismo error aparece en 25 de los 200 textos, todos de solicitudes con saldo negativo, y la solicitud 4 añade «una persona sola», sin ningún dato detrás. Apliqué a mano el protocolo del agente `revisor-de-explicaciones`, que agregué a la extensión porque la de la Tarea 7.1 solo tenía el auditor de equidad; no lo ejecuté dentro de Claude Code.

Tabla 2

Ejemplos reales (modelo Qwen2.5-0.5B-Instruct, generación determinista)

Solicitud	Datos	Texto del modelo de lenguaje (extracto)	Resultado
1 · 26 %	36 años; 18 meses; saldo entre 0 y 200	«…lo cual es alto para una persona con una edad de 36 años…»	Rechazada (clase): «alto» con probabilidad baja.
18 · 14 %	57 años; 11 meses; sin cuenta corriente	«…ya que la edad es mayor a 60 años y la duración de la cuenta es muy corta…»	Rechazada (clase): número no sustentado, 60.
8 · 43 %	23 años; 6 meses; saldo negativo	«…en una cuenta corriente sin saldo negativo.»	Pasó la clase; rechazada por las reglas 1 y 2.
118 · 36 %	47 años; 18 meses; sin cuenta corriente	«…ya que la edad es alta (47 años) y la duración de la cuenta es corta…»	Regla 2 inicial: falso motivo («riesgo alto»); tras el ajuste pasa.

Nota. Las probabilidades son las del predictor para la solicitud. Textos completos en evidencia/ejecucion_antes.txt.

Dos reglas nuevas

Regla 1 (`verificar_datos`). Compara el texto con la cuenta corriente y la vivienda de la solicitud. Reconoce cuatro afirmaciones de cuenta (saldo negativo, entre 0 y 200, de 200 o más, sin cuenta) y tres de vivienda (propia, alquilada, sin costo) con expresiones regulares, ignora las precedidas por «no», «sin» o «ni», y rechaza las que dicen algo distinto del dato o que afirman atributos que los datos no contienen (estado civil, hijos, empleo, ingresos). Regla 2 (`verificar_tono_medio`). Con probabilidad de 30 % a 60 %, extremos incluidos como en el texto de respaldo, rechaza que el texto califique de alto o bajo al riesgo o a la probabilidad. Ambas se conectaron a `verificar_explicacion`, que suma ahora `verificar_base` (el verificador de clase, conservado para medir el «antes») y las dos reglas. Cada regla tiene su archivo de pruebas y su commit: 46 pruebas la primera y 20 la segunda. Contra el verificador de clase fallan 10 de las 46 y 14 de las 17 iniciales (las de rechazo por aserción; el resto, por no existir la función), y con las reglas pasan todas, igual que las cinco originales (71 de 71).

Efecto de las reglas y falsos positivos

Tabla 3

Rechazos antes y después de las dos reglas, sobre los mismos textos

Motivo del rechazo	20 antes	20 después	200 antes	200 después
número no sustentado	4	4	29	29
tono incoherente (<30% o >60%)	5	5	37	37
contradice un dato (cuenta/vivienda)	0	3	0	25
afirmación sin dato	0	1	0	6
tono incoherente (30% a 60%)	0	8	0	65
Textos rechazados	**9**	**16**	**64**	**133**
Falsos positivos (texto correcto rechazado)	0	0	0	0
Textos incorrectos que se mostraron	8	1	91	22

Nota. Un texto con varios motivos cuenta en cada fila y una vez en «Textos rechazados»; la única afirmación absoluta (1 antes y 1 después) no se muestra. Incorrecto/correcto según lectura manual de cada texto contra sus datos (evidencia/etiquetas.json; un solo revisor). Salida de medir_efecto.py.

Los rechazos pasaron de 64 a 133 de 200 y los textos incorrectos que se mostraban, de 91 a 22; los 37 textos correctos siguieron mostrándose, es decir, ningún rechazo final fue un falso positivo. Sí hubo una regla que se disparó por un motivo falso: en las solicitudes 118 y 158 la Regla 2 leyó «la edad es alta (47 años)» como un juicio sobre el riesgo. El texto era incorrecto por otra causa (llama «duración de la cuenta» a la del crédito), pero con una frase correcta habría sido un falso positivo. Lo ajusté: «es alto/a» se ignora si lo precede edad, monto, duración, saldo o cuenta, salvo «lo cual», «lo que» o «esto», que sí se refieren al riesgo; dos pruebas nuevas fallaban antes del ajuste. El costo es que esos dos textos ahora pasan. También cambiaría el rechazo por revisión humana cuando haya una duda explícita («podría indicar un riesgo alto», solicitud 182).

Límites y recomendación

Tras las reglas, 22 de 200 textos incorrectos (11 %) siguen pasando y 8 más hacen afirmaciones evaluativas sin respaldo. Son cuatro patrones: el sentido de la probabilidad invertido (4; «hay una menor probabilidad de que el cliente pueda pagar» con 30 % de crédito malo), una cifra o un campo atribuido al lugar equivocado (14; «el monto total de la cuenta corriente es de $2058» para quien no tiene cuenta), frases incoherentes (3) y calificativos falsos (1; duración «muy corta» con 45 meses). Además, 30 de los 67 textos que pasan hablan de «euros» o «$» y los datos no traen moneda. Un verificador de reglas no puede cerrar esto del todo: cada regla enumera una forma de decir algo y el lenguaje tiene infinitas paráfrasis; saber si una cifra pertenece al campo mencionado, si un adjetivo describe lo correcto o si una inferencia conserva el sentido exige interpretar la oración, y las reglas solo cubren lo ya observado (los modelos de lenguaje producen afirmaciones fluidas pero no respaldadas; Ji et al., 2023). Además, las etiquetas son de un solo revisor y de un solo modelo pequeño.

Para un banco recomendaría: (a) no mostrar al cliente el texto libre del modelo de lenguaje, sino la explicación de respaldo armada con datos, y usar el modelo solo para borradores internos; (b) revisión humana obligatoria antes de cualquier texto que acompañe una negativa y siempre que la probabilidad esté entre 30 % y 60 % o falle una regla; (c) razones tomadas de las variables que de verdad pesaron en el predictor, registro de cada texto mostrado y auditoría periódica por muestreo con etiquetas humanas, incluida la equidad por grupo de la Tarea 7.1; y (d) tratarlo como sistema de alto riesgo, pues evaluar la solvencia de personas lo es en el Reglamento (UE) 2024/1689 y exige supervisión humana.

Referencias

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Hofmann, H. (1994). *Statlog (German Credit Data)* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5NC77

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Madotto, A., y Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys, 55*(12), Artículo 248. https://doi.org/10.1145/3571730

Qwen Team. (2024). *Qwen2.5 technical report*. arXiv. https://arxiv.org/abs/2412.15115

Unión Europea. (2024). Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas en materia de inteligencia artificial. *Diario Oficial de la Unión Europea*. https://eur-lex.europa.eu/eli/reg/2024/1689/oj